Prof Me. Daniel Vieira Disciplina: Data Science e Big Data

Aluno(a):
Curso:
Semestre:
Data:

A S&M Industry é uma empresa que atua no setor de manufatura industrial, desenvolvendo soluções e componentes utilizados em processos produtivos automatizados.

Sua unidade fabril opera com equipamentos industriais responsáveis por diferentes etapas da produção. Essas máquinas funcionam continuamente, sendo monitoradas por sensores que registram informações sobre suas condições de operação.

Nos últimos meses, a empresa identificou dificuldades relacionadas a paradas não planejadas de equipamentos. Essas interrupções podem comprometer o planejamento da produção, aumentar os custos de manutenção e afetar o cumprimento dos prazos de entrega.

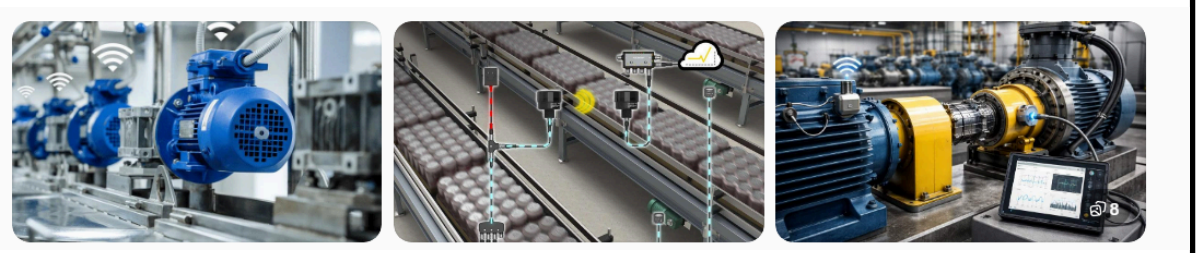
Atualmente, parte das decisões de manutenção é realizada de maneira corretiva, ou seja, após a identificação de um problema no funcionamento dos equipamentos.

Diante desse cenário, a direção da empresa decidiu investir em uma iniciativa de transformação digital, buscando utilizar os dados já coletados pelos sistemas industriais para apoiar decisões de manutenção.

Você foi contratado como Cientista de Dados para participar desse projeto.

Sua missão será investigar o histórico operacional das máquinas e desenvolver análises que auxiliem a empresa a compreender quais condições estão associadas às falhas dos equipamentos.

Como utilizar técnicas de Data Science, Machine Learning e Big Data para identificar padrões associados à ocorrência de falhas em equipamentos industriais e apoiar decisões de manutenção na S&M Industry Tech?



Os sistemas de monitoramento coletaram dados como:

Base de dados : [Dados de Manutenção]

	timestamp	maquina_id	temperatura_c	vibracao_mm_s	pressao_bar	corrente_a	horas_operacao	falha
0	2026-02-05 18:00:00	M04	61.97	3.37	5.59	22.48	10154.0	0
1	2026-01-22 13:00:00	M01	60.86	2.07	6.55	23.21	2687.0	0
2	2026-01-17 05:00:00	M03	70.35	2.75	6.21	26.36	11779.0	0
3	2026-01-19 16:00:00	M02	68.22	3.55	7.23	28.03	4519.0	0
4	2026-02-07 21:00:00	M01	73.89	2.64	5.89	25.73	9899.0	0

Etapa 1 — Análise exploratória com Pandas

Importar os dados, verificar tipos de variáveis, calcular estatísticas descritivas e investigar a frequência de falhas por equipamento.

Etapa 2 — Preparação e mineração de dados

Identificar dados ausentes, duplicatas e outliers. Realizar análises estatísticas, correlações e visualizações para descobrir padrões operacionais.

Etapa 3 — Machine Learning supervisionado

Treinar e comparar pelo menos dois algoritmos de classificação, utilizando métricas como acurácia, precisão, recall, F1-score e matriz de confusão.

Etapa 4 — Machine Learning não supervisionado

Aplicar K-Means para identificar grupos de condições operacionais semelhantes e analisar as características dos agrupamentos.

Etapa 5 — Big Data e tomada de decisão

Utilizar PySpark para processar uma versão ampliada do dataset, realizar transformações e agregações, e apresentar recomendações técnicas fundamentadas nas análises.

Desenvolvimento do projeto

Etapa 1 - Compreensão e exploração dos dados

1. Quantos registros e atributos existem no dataset?
2. Quais são as variáveis disponíveis e quais são seus respectivos tipos?
3. Qual é a distribuição das principais variáveis operacionais?
4. Quantos registros apresentam ocorrência de falhas? Qual é o percentual em relação ao total?
5. Qual equipamento apresenta a maior taxa de falhas?

Etapa 2 - Preparação e mineração de dados

1. Existem valores ausentes, registros duplicados ou possíveis outliers?
2. Quais procedimentos foram utilizados para tratar os problemas identificados? Justifique as escolhas.
3. Temperatura e vibração apresentam associação com a frequência de falhas?
4. Existe relação entre horas de operação e ocorrência de falhas?

5. Quais variáveis apresentam maior correlação com a variável falha?
6. A corrente elétrica apresenta associação com a ocorrência de falhas?

Etapa 3 - Machine Learning supervisionado

Objetivo: desenvolver e avaliar modelos capazes de classificar os registros operacionais quanto à ocorrência de falhas.

Algoritmos sugeridos: Árvore de Decisão, Random Forest e Regressão Logística.

Questões investigativas:

1. Quais atributos foram selecionados para o treinamento dos modelos? Justifique.
2. Como os dados foram divididos em conjuntos de treinamento e teste?
3. Qual algoritmo apresentou o melhor desempenho na classificação dos registros?
4. Como interpretar os resultados de acurácia, precisão, recall e F1-score?
5. Quais variáveis apresentaram maior relevância para as previsões dos modelos?
6. Qual é o impacto dos falsos positivos e falsos negativos no contexto da manutenção industrial?

Etapa 4 - Machine Learning não supervisionado

Objetivo: identificar agrupamentos de registros operacionais com características semelhantes, utilizando o algoritmo K-Means.

Questões investigativas:

1. É possível identificar diferentes perfis operacionais nos dados das máquinas?
2. Quantos agrupamentos foram identificados e como foi definida a quantidade de clusters?
3. Quais características operacionais definem cada agrupamento?
4. Existem clusters que apresentam maior frequência de falhas?

5. Como os agrupamentos identificados poderiam auxiliar no monitoramento das máquinas?

Etapa 5 - Big Data e tomada de decisão

Objetivo: utilizar Apache Spark para processar dados industriais e consolidar os resultados do projeto em recomendações para a S&M Industry Tech.

1. Como importar, explorar e processar os dados industriais utilizando PySpark?
2. Como realizar operações de filtragem, seleção e agrupamento utilizando Spark?
3. Quais são as principais diferenças entre Pandas e PySpark em relação à manipulação e ao processamento dos dados?
4. Como o processamento distribuído pode contribuir para a análise de grandes volumes de dados industriais?
5. Considerando os resultados das etapas anteriores, quais recomendações técnicas poderiam ser apresentadas à equipe de manutenção da S&M Industry Tech?

6. Entregáveis do projeto

Notebook do Google Colab contendo as 5 etapas do projeto com códigos, gráficos e interpretações.

Quais recomendações podem ser apresentadas à equipe de manutenção com base nos resultados obtidos ?

Essas recomendações precisam contemplar as principais descobertas, o modelo de classificação escolhido, suas limitações e possíveis ações para reduzir riscos operacionais.

Critério de avaliação

Critério	Pontuação
Exploração e compreensão dos dados	15
Preparação e tratamento	15
Análise exploratória e mineração	15
Machine Learning supervisionado	25
Machine Learning não supervisionado	10
Big Data com PySpark	10
Interpretação e recomendações	10
Total	**100**